

**SVEUČILIŠTE JOSIPA JURJA STROSSMAYERA U OSIJEKU**  
**FAKULTET ELEKTROTEHNIKE, RAČUNARSTVA I**  
**INFORMACIJSKIH TEHNOLOGIJA**

**Diplomski sveučilišni studij računarstva**

**SEGMENTACIJA SRCA IZ 3D SLIKA MAGNETSKE**  
**REZONANCE (MRI)**

**Tea Krčmar**

**Osijek, 2023.**

# SADRŽAJ

1. UVOD.....	1
2. PREGLED PODRUČJA I PROBLEMATIKE.....	2
3. PRIKUPLJANJE I OPIS KORIŠTENIH PODATAKA.....	3
3.1. Magnetska rezonanca (MRI) .....	3
3.2. Korišteni skup podataka .....	4
3.3. NIfTI format.....	5
3.4. Klinička pozadina .....	6
4. MODEL NEURONSKE MREŽE .....	7
4.1. Konvolucijske neuronske mreže .....	7
4.2. U-Net arhitektura.....	9
5. TRENIRANJE NEURONSKE MREŽE.....	10
5.1. Predobrada podataka .....	10
5.2. Model 3D-Unet arhitekture.....	11
5.3. Analiza rezultata .....	13
6. ZAKLJUČAK .....	16
7. LITERATURA.....	17

## 1. UVOD

Kardiovaskularne bolesti vodeći su uzrok smrti u svijetu, s procjenom od 17.9 milijuna godišnjih slučajeva [1]. Zbog visoke brojke godišnjih slučajeva i s namjerom uspostave odgovarajućeg tretmana u što kraćem vremenskom roku, u zadnjih 50 godina dolazi do razvoja tehnologija koje bi pomogle pri ranijem primjećivanju bolesti srca. Razvojem magnetske rezonance omogućeni su brži i manje invazivni načini skeniranja srca, a segmentacijom je omogućeno uklanjanje nepotrebnih informacija. Segmentacija slika magnetske rezonance proces je izoliranja i prepoznavanja područja interesa u svrhu detaljnije interpretacije i analize. Može biti obavljena od strane kliničkog stručnjaka ili pomoću softverskih algoritama za obradu slika [2].

Cilj ovoga rada jest razviti i evaluirati model za segmentaciju cijelog srca pomoću 3D U-Net arhitekture i koristeći tehnologije Python, Keras i Tensorflow. U teorijskom dijelu rada biti će opisan način dobivanja slika magnetskom rezonancom i skup podataka korišten za analizu, istražena klinička pozadina srca i objašnjene osnove konvolucijskih neuronskih mreža. Model i optimizacija biti će ispitani kako bi se došlo do što boljih segmentacijskih rezultata.

## 2. PREGLED PODRUČJA I PROBLEMATIKE

Segmentacija srca iz skenova magnetske rezonance (MRI) vremenski je zahtjevan, ali važan posao u medicinskoj dijagnostici. Omogućuje analizu pojedinih dijelova srca i pruža važne informacije o anatomiji i funkcionalnosti srca (kvantitativnu analizu volumena srca, izračunavanje različitih parametara srčane funkcije, praćenje promjena srca u vremenu, itd.), kao i olakšavanje planiranja operativnih zahvata. Izvodi se ručno od strane kliničkih stručnjaka ili od strane specijalizirane medicinske programske podrške (potpuno automatizirane[3] ili polu-automatizirane[4]).

Osim vremenske zahtjevnosti i potrebe za kliničkim stručnjacima, postoje drugi čimbenici koji segmentaciju srca iz MRI skenova čine izazovnom: kontrast i rezolucija slike, varijacije anatomije srca, artefakti (pokreti disanja, nehomogenost magnetskog polja) i šum, složenost srčane strukture i volumetrijska segmentacija (računski intenzivna zbog broja slika). Da bi se prevladali ovi izazovi, razvijene su brojne metode segmentacije srca, uključujući pristupe bazirane na rubovima, intenzitetu piksela, regijama i modele bazirane na strojnom učenju [5].

Jedna od najčešće korištenih arhitektura za segmentaciju srca iz 3D MRI slika je 3D U-Net. Nastala kao proširenje 2D U-Net arhitekture za segmentaciju 2D slika, ova arhitektura sastoji se od nekoliko slojeva konvolucije, down-samplinga i up-samplinga koji joj omogućuju preciznu segmentaciju anatomskih struktura srca iz 3D MRI slika. Kao pomoć pri izdvajanju značajki iz slika i smanjenju broja parametara modela, 3D U-Net arhitektura koristi blokove konvolucije i poolinga [6]. Druga popularna arhitektura je DeepLab. Ova arhitektura temelji se na dilatiranim konvolucijskim slojevima koji omogućuju šire receptivno polje, što je posebno korisno za segmentaciju objekata različitih veličina. DeepLab često koristi tehnike kontekstualnih modula za bolje razumijevanje konteksta slike. Treća popularna arhitektura je DeepMedic. DeepMedic je duboka neuronska mreža koja koristi konvolucijske i pooling slojeve kako bi izdvojila značajke iz MRI slika. Ova arhitektura koristi multimodalni pristup koji uključuje kombiniranje informacija iz više modaliteta slike kako bi se poboljšala segmentacija [7]. Uz navedene arhitekture, koriste se i druge metode za segmentaciju srca iz 3D MRI slika, poput V-Net arhitekture, metode bazirane na prijenosnom učenju (eng. *deep learning*), metode bazirane na regiji interesa (ROI) te u zadnjih par godina kombinacije različitih metoda kako bi se poboljšala kvaliteta i preciznost segmentacije.

Osim segmentacije anatomskih struktura, neuronske mreže se koriste i za detekciju i dijagnostiku bolesti (tumori, artritis, ozljede ligamenata i slično).

### 3. PRIKUPLJANJE I OPIS KORIŠTENIH PODATAKA

U ovom poglavlju opisuje se skup korištenih podataka za treniranje segmentacijskog modela srca, način na koji je prikupljen i format u kojemu je zapisan. Također će biti opisana klinička pozadina skupa podataka.

#### 3.1. Magnetska rezonanca (MRI)

Pomoću radiovalova i snažnog magnetskog polja, dijagnostička metoda poznata kao magnetska rezonanca (MRI) može pružiti precizne slike unutrašnjosti tijela. U medicini se MRI često koristi za dijagnosticiranje i praćenje različitih bolesti i stanja (analiza tumora, krvnih ugrušaka, upala, rana i drugih nepravilnosti u tijelu).

Za dobivanje MRI slike, pacijent se smješta unutar velikog magneta (nazvanog MRI skener) i mora ostati miran tijekom postupka snimanja kako ne bi zamutio sliku. MRI koristi snažne magnete koji stvaraju homogeno magnetsko polje koje prisiljava protone vodika u tijelu da se usklade s tim poljem. Kada se kroz pacijenta pulsira radiofrekvencijska struja, protoni se stimuliraju i izlaze iz ravnoteže. Kako se magnetsko polje mijenja, protoni vodika se kreću i rotiraju stvarajući elektromagnetske signale koje hvataju antene u MRI uređaju. Isključivanjem radiofrekvencijskog polja senzori MRI-a mogu otkriti energiju koja se oslobađa pri ponovnom usklađivanju protona s magnetskim poljem. Vrijeme koje je potrebno protonima da se ponovno usklade s magnetskim poljem, kao i količina oslobođene energije, mijenja se ovisno o okolišu i kemijskoj prirodi molekula [8].


Ti signali su analogni, kontinuirani signali koji se moraju pretvoriti u digitalni oblik kako bi se koristili za stvaranje slike. Za digitalizaciju podataka koriste se pretvarači analognog u digitalni oblik koji pretvaraju kontinuirane signale u diskretne vrijednosti. Nakon pretvorbe u diskretne vrijednosti, signali se grupiraju u matricu k-prostora, pri čemu svaka točka u matrici predstavlja diskretni uzorak originalnog signala. Dimenzije matrice k-prostora određene su veličinom i razlučivošću željene slike. Što je veća matrica k-prostora, slika će biti detaljnija, ali će vrijeme snimanja biti duže. Jedan od najčešće korištenih algoritama koji se primjenjuje na matricu za dobivanje konačnih slika je Fourierova transformacija koja omogućuje prikaz signala u frekvencijskoj domeni. Na taj način se dobivaju podaci o različitim frekvencijskim komponentama signala koji se potom koriste za stvaranje slika u prostornoj domeni[9].

Slike tijela pacijenta mogu se snimiti u različitim ravninama, ovisno o položaju i orijentaciji magnetskog polja MRI uređaja u odnosu na subjekt. Tri najtipičnije ravnine za dobivanje MRI slika, a prikazane na slici 1 su:

- Aksijalna ravnina ili transverzalna ravnina – tijelo pacijenta je podijeljeno na gornju i donju polovicu. Kada se snimaju MRI slike u transverzalnoj ravnini, slike se prikazuju u horizontalnom pogledu, pri čemu je gornji dio tijela pacijenta prikazan na vrhu slike, a donji dio prikazan na dnu slike. Ova se ravnina često koristi za snimanje mozga.
- Sagitalna ravnina – ova ravnina dijeli tijelo pacijenta na lijevu i desnu polovicu. Slike se prikazuju u bočnom pogledu, pri čemu je lijeva strana tijela pacijenta prikazana na desnoj strani slike, a desna strana na lijevoj strani slike. Ova ravnina se često koristi za pregled mozga i kralježnice.
- Koronalna ravnina – ova ravnina prolazi kroz tijelo pacijenta i dijeli ga na prednju (ventralnu) i stražnju (dorsalnu) polovicu. Ova ravnina se također naziva frontalna ravnina jer se obično prikazuje u frontalnom ili prednjem pogledu. Široko se koristi u

ortopediji za pregled zglobova i kostiju, uključujući koljena, stopala, gležnjeve i kukove [10].


U nekim slučajevima koriste se 3D slike koje prikazuju strukture unutar tijela pacijenta u trodimenzionalnom prostoru što omogućuje detaljniji pregled unutarnjih organa i struktura [11]. Prednost MRI-a naspram ovakvih tehnologija je detaljnije i preciznije prikazivanje mekih tkiva i organa te neupotreba ionizirajućeg zračenja.



Slika 1. Koronalna, sagitalna i aksijalna ravnina srca [12].


### 3.2. Korišteni skup podataka

Skup podataka koji se koristio u sklopu ovoga rada pružen je od strane *MICCAI 2017 Multi-Modality Whole Heart Segmentation Challenge*-a, a njegova vizualizacija prikazana je na slici 2. Skup podataka sadrži 20 volumetrijskih kardioloških slika dobivenih iz stvarnog kliničkog okruženja, pri čemu za svaki modalitet postoji 20 volumena s pripadajućom referentnom oznakom (oznake). Priložene referentne oznake sadrže sve podstrukture srca od gornjeg abdomena do uzlazne aorte, uključujući lijevu klijetku, miokard lijeve klijetke, desnu klijetku, desnu pretklijetku, lijevu pretklijetku, uzlaznu aortu i plućnu arteriju.



Slika 2. Vizualizacija korištenog skupa podataka [13].

Presjeci su dobiveni u aksijalnom pogledu. Ravninska rezolucija iznosi otprilike  $0,78 \times 0,78$  mm, a prosječna debljina presjeka je 1,60 mm. Podaci za MRI su dobiveni korištenjem 3D ravnotežne slobodne precesije (b-SSFP) sekvenci, s rezolucijom akvizicije od oko 2 mm u svakom smjeru, te rekonstruirani na otprilike 1 mm, što rezultira volumetrijskim podacima koji se sastoje od 120 do 200 dvodimenzionalnih presjeka.




*Slika 3. Aksijalni (gornji lijevi kut), koronalni (donji lijevi kut) i sagitalni (donji desni kut) prikaz srca s oznakama.*

### 3.3. NIfTI format

NIfTI (Neuroimaging Informatics Technology Initiative) format standardni je format za pohranu i distribuciju medicinskih slika, posebno u području neuroznanosti. Ovaj format koristi se za 3D volumetrijske podatke poput MRI i CT skenova i PET slika. NIfTI format omogućava pohranu samih slika, kao i metapodataka poput orijentacije, rezolucije, prostornog položaja i drugih informacija o slici. Pohrana samih slika nalazi se u blokovima podataka, dok se metapodaci nalaze u glavnom zaglavlju. Ove datoteke obično imaju ekstenziju ".nii" ili ".nii.gz", pri čemu ".nii.gz" označava da je datoteka stisnuta GZIP kompresijom. Datoteka s ovom ekstenzijom sadrži i glavno zaglavlje i blokove podataka, dok datoteke spremljene s ekstenzijom ".hdr" i ".img" sadrže zaglavlje i blokove podataka, ali odvojene. [14]

NIfTI format ima široku primjenu u znanstvenim istraživanjima, kliničkoj dijagnostici i programima za analizu medicinskih slika. Njegova popularnost proizlazi iz činjenice da je otvorenog koda, podržava različite modalitete skeniranja i omogućava jednostavno čitanje i pisanje podataka u programskim jezicima i softverskim okruženjima.

Slike ranije spomenutog skupa podataka spremljene su u NIfTI formatu, a proučavane u programskom alatu Slicer 5.0.3. *Slika 3.* prikazuje vizualizaciju srca u Slicer-u te prikaze srca u određenim ravninama. Za korištenje NIfTI formata u Pythonu, potrebno je uvesti biblioteku *nibabel* i koristiti funkciju *load()* za učitavanje slike. Funkcija *get\_fdata()* koristi se za dohvaćanje podataka. Slika se zatim sprema u trodimenzionalni tenzor, a za njen prikaz korištena je naredba *imshow()* iz biblioteke *matplotlib*, kao što je prikazano na slici 4.



*Slika 4. MRI sken (koronalni prikaz) i pripadajuća segmentacijska maska.*

### 3.4. Klinička pozadina

Segmentacija cijelog srca važan je postupak u medicini koji se koristi za identifikaciju i izolaciju različitih anatomskih struktura srca na medicinskim slikama. Ova segmentacija omogućuje kvantitativnu analizu i procjenu funkcije srca, kao i praćenje promjena tijekom vremena. Klinička pozadina segmentacije cijelog srca uključuje: dijagnostiku, procjenu funkcije srca, planiranje tretmana i praćenje promjena.

Segmentacija cijelog srca omogućuje preciznu vizualizaciju i analizu različitih dijelova srca, što je ključno za dijagnostiku i planiranje liječenja srčanih bolesti. Ona također omogućuje kvantitativnu procjenu parametara kao što su volumen krvi u komorama srca, ejeckijska frakcija (eng. *ejection fraction*, EF), debljina stijenki srca i kontraktilnost srčanog mišića. Ovi parametri pružaju informacije o funkciji srca i mogu pomoći u dijagnozi i praćenju bolesti srca. Isto tako može pomoći u planiranju kirurških zahvata na srcu, uključujući presađivanje srca, koronarnu arterijsku prenosnicu (CABG) i postavljanje srčanih prenosnika (stentova). Redovita segmentacija srca tijekom vremena omogućuje praćenje promjena u anatomiji i funkciji srca, kao i učinkovitost liječenja. To može biti od koristi u praćenju napredovanja bolesti, procjeni učinka terapije ili praćenju oporavka nakon srčanog udara ili operacije.



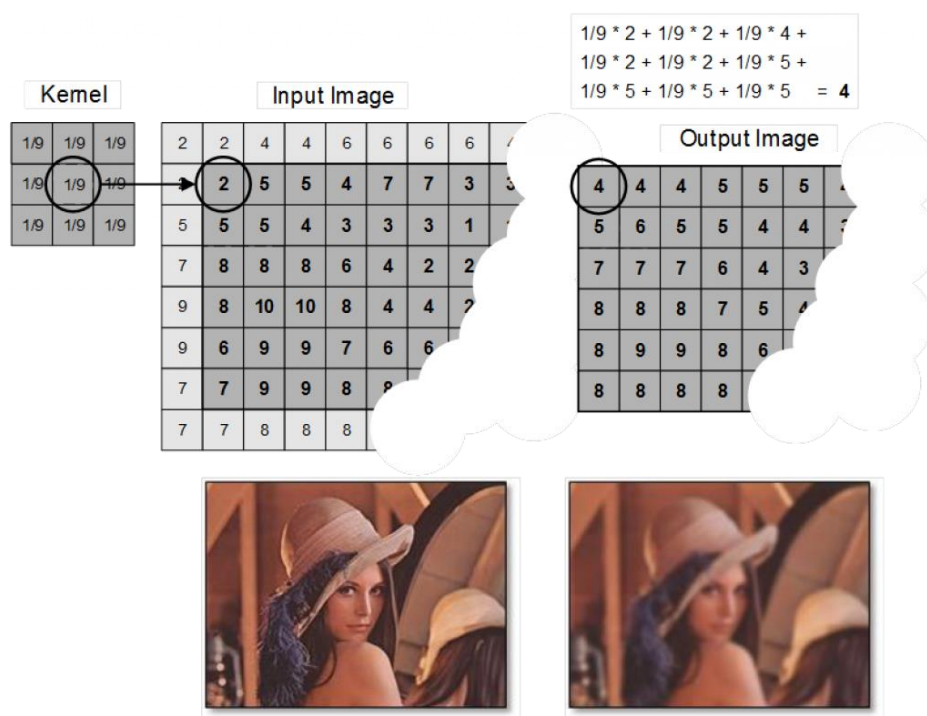
## 4. MODEL NEURONSKE MREŽE

U ovome poglavlju biti će opisane konvolucijske mreže, njihov princip rada i U-Net arhitektura neuronske mreže.

### 4.1. Konvolucijske neuronske mreže

Konvolucijske neuronske mreže (eng. *Convolutional Neural Networks*, CNN) vrsta su neuronskih mreža koja je dizajnirana za obradu podataka koji imaju prostornu strukturu. One su široko korištene u području računalnog vida za zadatke kao što su klasifikacija slika, detekcija objekata, segmentacija slika i druge. Inspirirane strukturom vizualnog korteksa u ljudi, sastoje se od slojeva konvolucijskih filtara.


Konvolucijski slojevi primjenjuju niz filtara (jezgri, eng. *kernel*) na ulazne podatke kako bi izvukli značajke iz njih. Konvolucijski filteri su matrice težina koje se mogu trenirati kako bi se prepoznale različite značajke. Kernel je mala matrica (obično dimenzija 3x3 ili 5x5) koja se pomakne po slici s korakom (eng. *stride*) i množi s pikselima slike na svakom mjestu poklapanja. Prilikom množenja, pikseli slike i elementi kernela se pomnože, a rezultati se zbroje kako bi se dobio jedan broj koji predstavlja značajku tog dijela slike. Proces se ponavlja za svaki piksel na slici, čime se generira skup značajki koji predstavlja informacije o različitim dijelovima slike, kao što je prikazano na slici 5. Ovaj postupak omogućuje konvolucijskoj mreži da nauči lokalne značajke, poput rubova, tekstura ili oblika, jer se kerneli mogu prilagoditi za izdvajanje određenih karakteristika iz slike.



Slika 5. Operacija konvolucije pri zamućivanju slike.

Nadalje, konvolucijske mreže često koriste i slojeve za agregaciju (eng. *pooling layers*) koji smanjuju prostornu dimenzionalnost izlaza konvolucijskih slojeva. Najčešći način

agregacije je maksimalno uzorkovanje (eng. *max pooling*), gdje se izdvaja maksimalna vrijednost iz svake lokalne regije izlaza konvolucijskog sloja. Slika 6 to i prikazuje.



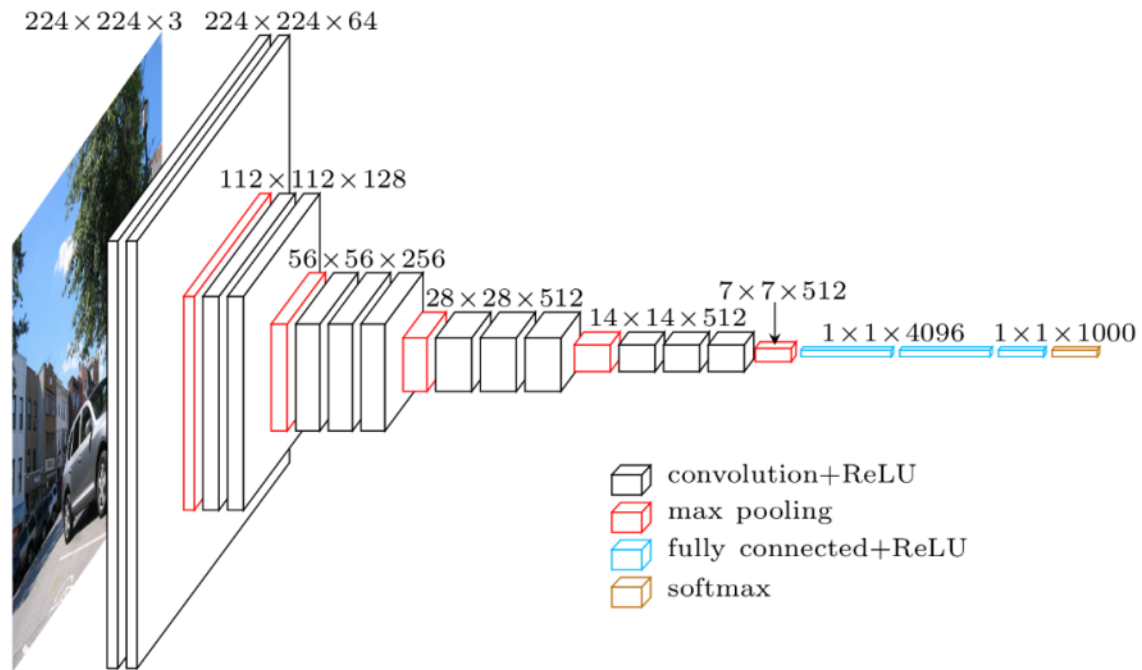
Slika 6. Operacija maksimalnog sažimanja.

Konvolucijske mreže također mogu sadržavati potpuno povezane slojeve (eng. *fully connected layers*) na kraju arhitekture, koji se koriste za klasifikaciju ili regresiju na temelju izvučenih značajki. Potpuno povezani slojevi su slojevi u neuronskim mrežama u kojima su svi neuroni povezani sa svim neuronima prethodnog sloja. Izlazni vektori neurona se obrađuju kako bi se donijela konačna klasifikacijska odluka te svaki neuron u potpuno povezanom sloju ima svoju aktivacijsku funkciju. Aktivacijske funkcije su ključne jer utječu na aktivnost neurona u neuronskoj mreži. Omogućuju neuronskoj mreži da nauči nelinearne funkcije i obavlja kompleksne zadatke.

Najčešće korištene aktivacijske funkcije su:

- ReLU (eng. *Rectified Linear Unit*) koja se često koristi u skrivenim slojevima neuronske mreže. ReLU aktivacijska funkcija je definirana kao maksimum između nule i ulaznog signala. Ona potiskuje negativne vrijednosti i linearno aktivira pozitivne vrijednosti.
- Sigmoidna funkcija se koristi kao funkcija odluke za binarnu klasifikaciju. Ona stisne ulazne vrijednosti u rasponu između 0 i 1, što ih može interpretirati kao vjerojatnosti.
- Softmax funkcija se koristi kao funkcija odluke za višeklasnu klasifikaciju. Ona stisne ulazne vrijednosti u rasponu između 0 i 1 te ih normalizira tako da zbroj svih izlaznih vrijednosti bude jednak 1. Time se izlazi mogu interpretirati kao vjerojatnosti za svaku moguću klasu.

Sve navedene komponente zajedno čine konvolucijsku neuronsku mrežu. Prednosti konvolucijskih mreža uključuju sposobnost automatskog izvlačenja značajki iz podataka, invarijantnost na translacije i lokalne varijacije te efikasnost u obradi prostornih podataka. Zbog tih svojstava, konvolucijske mreže postigle su izvanredne rezultate u mnogim zadacima računalnog vida i postale su ključna tehnologija u području umjetne inteligencije. Primjer konvolucijske mreže vidljiv je iz slike 7.



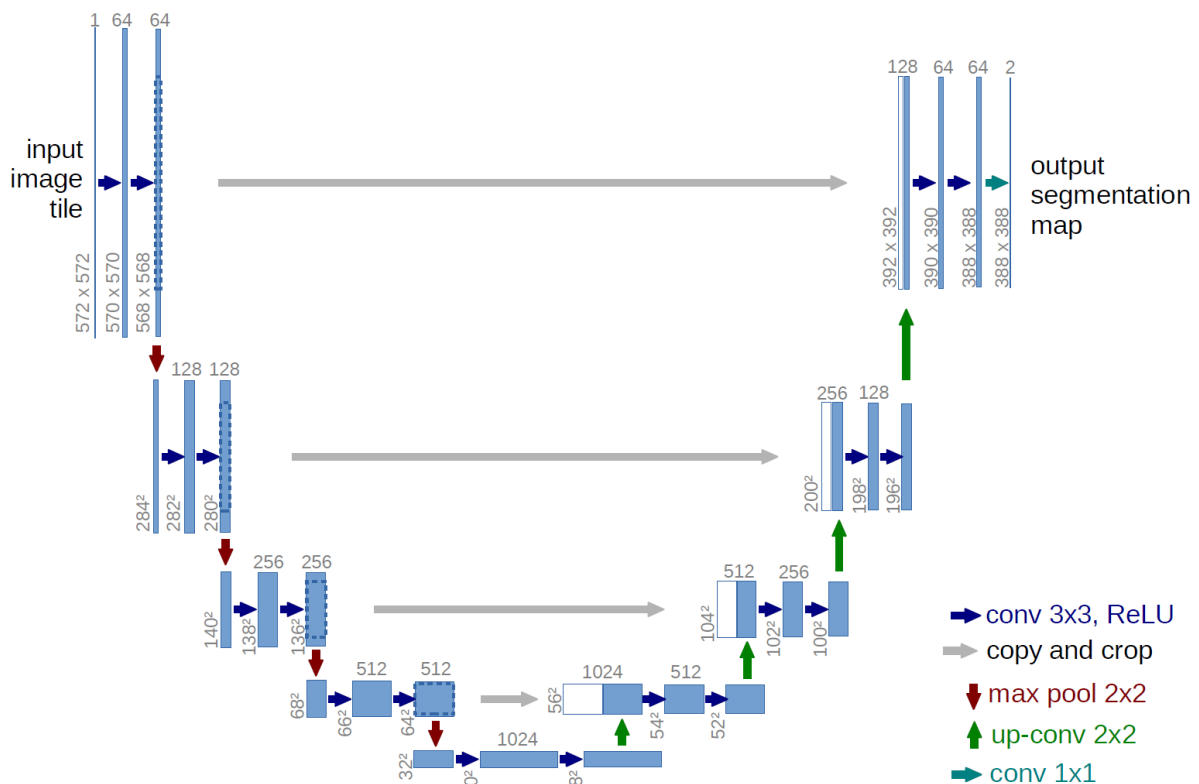
Slika 7. Primjer konvolucijske neuronske mreže.

## 4.2. U-Net arhitektura

U-Net arhitektura tip je konvolucijske neuronske mreže nastao za segmentaciju medicinskih slika. Nazvana je U-Net zbog svog oblika koji podsjeća na slovo "U", a ideja joj je da koristi velik broj filtriranja u konvolucijskim slojevima za učenje značajki iz slika i održavanje prostornih informacija.

U-Net arhitektura se sastoji od tri dijela: enkodera (ulazni slojevi), dekodera (izlazni slojevi) i mosta koji ih povezuje. Enkoder ima tipičnu arhitekturu konvolucijske mreže koja se koristi za ekstrakciju značajki iz ulazne slike. Sastoji se od serije konvolucijskih slojeva i slojeva za uzorkovanje (eng. *downsampling*), poput slojeva sažimanja (eng. *max-pooling*) ili slojeva za konvoluciju s preskočnim vezama (eng. *skip connections*). Ovi slojevi postupno smanjuju prostornu rezoluciju slike, ali povećavaju broj značajki koje se izlučuju. Dekoder, s druge strane, koristi slojeve za proširivanje (eng. *up-sampling*) kako bi povećao prostornu rezoluciju i rekonstruirao segmentirani izlaz. Također koristi slojeve za konvoluciju s preskočnim vezama kako bi omogućio informacijski prijenos iz enkodera u dekoader. Ova arhitektura vizualno je prikazana na slici 8.

U-Net arhitektura posebno je korisna za segmentaciju slika jer kombinira lokalne i globalne informacije. Lokalne informacije se dobivaju kroz konvolucijske slojeve, dok se globalne informacije prenose kroz slojeve s preskočnim vezama koji omogućuju modelu da nauči vezu između niskih i visokih razina značajki.



Slika 8. U-Net arhitektura [15].

## 5. TRENIRANJE NEURONSKE MREŽE

U ovome poglavlju biti će objašnjeni postupci pri treniranju neuronske mreže, njeni parametri, evaluacija modela, i proces pripreme slika prije njena treniranja.

### 5.1. Predobrada podataka

Kao što je objašnjeno u podpoglavlju 3.2., korišteni skup podataka sastoji se od 20 MRI slika i pripadajućih maski (eng. *labels*). S obzirom na malen skup podataka kojima se raspolaže, od 20 slika 18 je predviđeno za treniranje i validaciju modela, dok su dvije slike predviđene za evaluaciju modela. Skup za treniranje i validaciju podijeljen je također u dva dijela: *train\_data* i *val\_data*, gdje *train\_data* predstavlja podatke predviđene za treniranje modela (80%), a *val\_data* predstavlja podatke za evaluaciju (20%).


Trodimenzionalna segmentacija računalno je zahtjevna te je potrebno podatke obraditi prije samoga treniranja. U korištenom setu podataka, slike su dolazile u dimenzijama od 288 x 288 x 120 (najmanja) do 512 x 512 x 160 (najveća). Prvi korak bio je svesti sve slike na jednake dimenzije (prikaz rezultata na slici 9) koje bi mogle stati u memoriju, a zatim ih testirati u eksperimentalnom okruženju.

Isprobano je nekoliko dimenzija u nekoliko grupa (eng. *batch*) na nekoliko sličnih arhitektura:

- Batch od jednog podatka dimenzija 256 x 256 x 256

- Batch od jednog podatka dimenzija 128 x 128 x 128
- Batch od dva podatka dimenzija 128 x 128 x 128
- Batch od jednog podatka dimenzija 64 x 64 x 64
- Batch od dva podatka dimenzija 64 x 64 x 64
- Batch od jednog podatka dimenzija 32 x 32 x 32
- Batch od dva podatka dimenzija 32 x 32 x 32

U prvome slučaju dolazilo je do preopterećenja RAM-a i GPU-a te se odustalo od te veličine. Ostale dimenzije nisu preopteretile memoriju te se nakon provedenih eksperimenata ispostavilo da batch od jednog podatka dimenzija 128 x 128 x 128 daje najbolje rezultate. U slučaju gdje je batch dva za dimenzije 128 x 128 x 128 dolazi do lošijih rezultata, dok u preostalim slučajevima dolazi do prevelikog gubitka informacija i loših rezultata. Što su slike bliže originalnoj dimenzijskoj veličini, rezultati su bolji.



*Slika 9. Prikaz promijenjenih dimenzija slika.*

## 5.2. Model 3D-Unet arhitekture

U svrhu rada korišten je model 3D-Unet arhitekture. Prilikom dolaska 3D ulazne slike dimenzija 128 x 128 x 128 x 1 slijedi smanjivanje dimenzionalnosti (eng. *downsampling*) koji se sastoji od nekoliko slojeva. Svaki sloj ima konvolucijski sloj, sloj normalizacije po grupama (eng. *Batch Normalization*) i sloj aktivacije ReLU. Nakon toga se koristi sloj za maksimalno



uzorkovanje (eng. *MaxPooling3D*) koji smanjuje rezoluciju slike. Slijedi centralni sloj (eng. *Bottleneck*) koji se sastoji od dva konvolucijska sloja s Batch Normalization i Dropout slojem (vrijednost 0.5) za reguliranje. Nakon toga slijedi put povećavanja rezolucije u dekoderskom dijelu koji se sastoji od konvolucijskih slojeva, slojeva za uspinjanje (eng. *Conv3DTranspose*) i konkatenacija (eng. *Concatenate*). Slojevi za uspinjanje povećavaju prostornu rezoluciju slike, a konkatenacija kombinira značajke iz odgovarajućih slojeva putem konkatenacije. Struktura korištene arhitekture prikazana je u tablici 1. Raspon filtara mreže je od 32 do 512. Na samome kraju koristi se *softmax* aktivacija za višeklasnu klasifikaciju s 8 izlaznih kanala. Mreža sadrži 22 587 336 parametara od kojih su 22 581 448 omogućeni za treniranje.

Sloj	Operacija	Izlazna veličina	Korak
<b>Input</b>	-	(128, 128, 128, 1)	-
<b>Conv1</b>	Conv3D(32, 3)	(128, 128, 128, 32)	-
	MaxPooling3D	(64, 64, 64, 32)	(1, 2, 2)
<b>Conv2</b>	Conv3D(64, 3)	(64, 64, 64, 64)	-
	MaxPooling3D	(32, 32, 32, 64)	(2, 2, 2)
<b>Conv3</b>	Conv3D(128, 3)	(32, 32, 32, 128)	-
	MaxPooling3D	(16, 16, 16, 128)	(1, 2, 2)
<b>Conv4</b>	Conv3D(256, 3)	(16, 16, 16, 256)	-
	MaxPooling3D	(8, 8, 8, 256)	(1, 2, 2)
<b>Conv5</b>	Conv3D(512, 3)	(8, 8, 8, 512)	-
	Dropout(0.5)	(8, 8, 8, 512)	-
<b>Up6</b>	Conv3DTranspose(256, 2)	(16, 16, 16, 256)	(1, 2, 2)
<b>Up7</b>	Conv3DTranspose(256, 2)	(32, 32, 32, 256)	(1, 2, 2)
<b>Up8</b>	Conv3DTranspose(128, 2)	(64, 64, 64, 128)	(2, 2, 2)
<b>Up9</b>	Conv3DTranspose(64, 2)	(128, 128, 128, 64)	(1, 2, 2)
<b>Output</b>	Conv3D(8, 1)	(128, 128, 128, 8)	-

Tablica 1. Struktura 3D U-Net arhitekture.

Pri treniranju modela korištena je optimizacijska funkcija Adam, a za funkciju gubitka korištene su *dice loss*, *categorical\_crossentropy* i *jaccard indeks*. Dice funkcija mjeri preklapanje između predviđene segmentacije i stvarne segmentacijske slike. Opisana je ovom formulom:

$$dice(A, B) = \frac{2 \times |A \cap B|}{|A| + |B|}$$

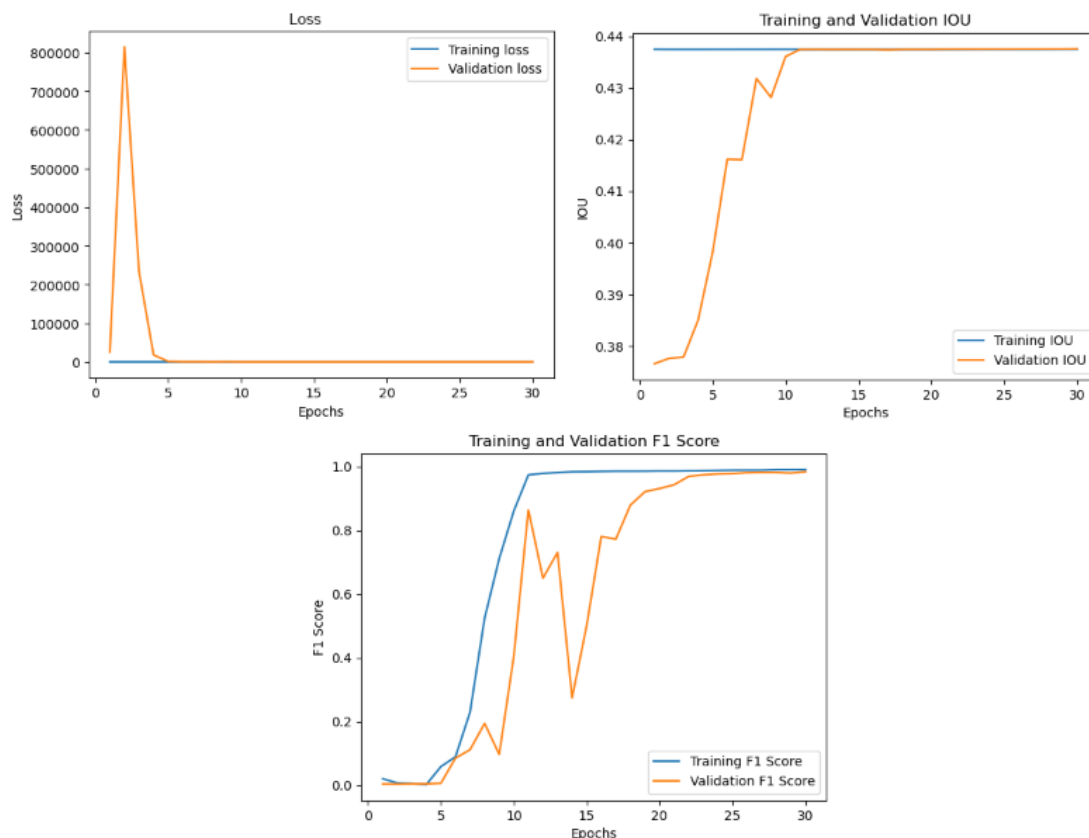
gdje je A segmentacijski rezultat, a B je odgovarajuća segmentacijska slika. Dice funkcija vratila je rezultat od ~95%. Druga funkcija koja je korištena je *jaccard indeks*. Jaccard funkcija opisana je ovom formulom:

$$jaccard(A, B) = \frac{|A \cap B|}{|A \cup B|}$$

gdje je A segmentacijski rezultat, a B je odgovarajuća segmentacijska slika. Vraćeni rezultat je ~90%.

### 5.3. Analiza rezultata

Prvenstveno treniran na 100 epoha, nakon uočavanja prestanka promjene na validacijskom setu, model je zaustavljen na 30 epoha. Time se izbjegava pretjerano učenje na predanom setu podataka i sprema težine neurona s najboljim rezultatima. Rezultati treniranja na trening i validacijskom setu prikazani su na slici 10. Na samom početku postoji značajan gubitak informacija u validacijskom setu, koji se nakon pete epohe usklađuje s malim gubitcima trening seta. Jaccard indeks ima značajan skok od pete do desete epohe, gdje se izjednačava na vrijednosti 0.4375, dok se dice koeficijent usklađuje nakon 25-te epohe.



Slika 10. Grafovi gubika *categorical\_crossentropy*, jaccard indeks i dice koeficijenta.

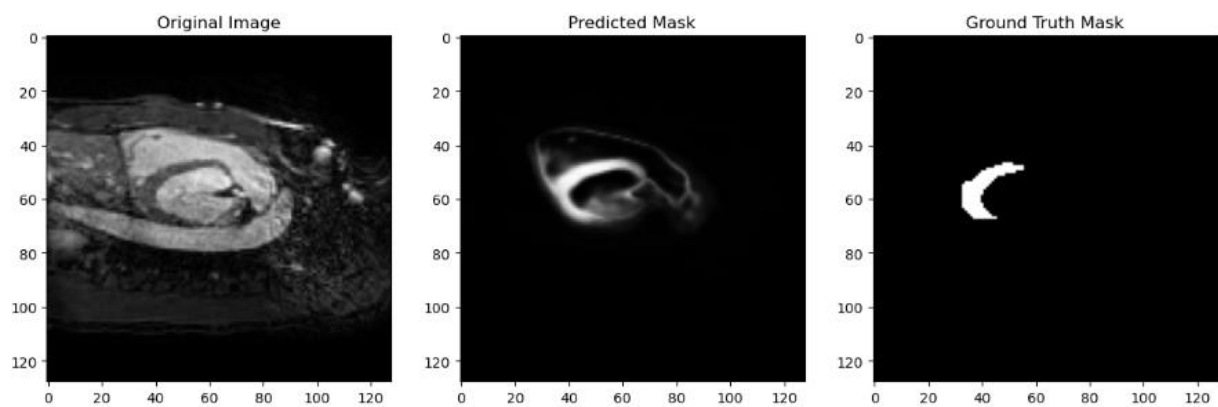
Provedena evaluacija nad testnim skupom podataka vratila je poprilično slične rezultate (u odnosu testnih slika jedne naspram druge). Rezultati na testnom skupu podataka prikazani su u tablici 2.

Testni podatak	Dice funkcija	Jaccard funkcija
<b>Slika_1</b>	0.9454	0.8965
<b>Slika_2</b>	0.9529	0.9100

Tablica 2. Evaluacijski rezultati nad testnim skupom.

Na slici 11 prikazan je sagitalni pogled testirane segmentacije. Prva slika prikazuje originalnu magnetnu rezonancu srca, druga prikazuje predviđenu segmentaciju srca, i treća prikazuje originalnu segmentaciju od strane stručne osobe. Vidljivo je da predviđena segmentacija obuhvaća i prostor van originalne segmentacije, ali i obuhvaća cjelokupni prostor originalne segmentacije, što ukazuje na dovoljno dobro predviđanje strukture.





*Slika 11. Sagitalni prikaz originalne MRI slike, predviđene segmentacije i originalne segmentacije srca.*

Prema rezultatima i samome prikazu, model je uspješno izvršio svoj zadatak segmentacije iako se na preciznosti segmentacije može poraditi.

## 6. ZAKLJUČAK

Proces segmentacije srca i izrada modela 3D U-Net arhitekture za segmentaciju srca iz 3D MRI slika važan je posao u medicinskoj dijagnostici. Ona omogućuje analizu pojedinih dijelova srca i pruža važne informacije o anatomiji i funkcionalnosti srca kao i olakšavanje planiranja operativnih zahvata. Vremenski je zahtjevan posao za kliničke stručnjake te bi mogućnost polu-automatske segmentacije uvelike smanjila vrijeme segmentiranja, a u isto vrijeme omogućila kontrolu preciznosti od strane stručnog osoblja.

U ovome radu predložena je struktura 3D U-Net modela za segmentaciju srca iz MRI slika. Opisan je način dobivanja slika magnetskom rezonancom, format u kojemu se slike nalaze, predobrada podatkovnog skupa, objašnjene su konvolucijske neuronske mreže i način na koji rade te 3D-Unet arhitektura korištena u svrhu ovoga rada. Na kraju su analizirani i prikazani rezultati evaluacije modela. Rezultati pokazuju da 3D-Unet arhitektura predstavlja prikladan pristup za zadatke segmentacije srca. Povećanjem skupa podataka za treniranje bi se osigurali bolji rezultati, kao i upotreba naprednijih tehnika pretprocesiranja i lokalizacije.

## 7. LITERATURA

- [1] WHO., [https://www.who.int/health-topics/cardiovascular-diseases#tab=tab\\_](https://www.who.int/health-topics/cardiovascular-diseases#tab=tab_) (13. ožujak 2023)
- [2] Habijan, M., Galić, I., Leventić, H., & Babin, D. (2020). Neural Network Based Whole Heart Segmentation from 3D CT Images. *International Journal of Electrical and Computer Engineering Systems*, 25-31.
- [3] Leventić, H. et al, (2018). Left atrial appendage segmentation from 3D CCTA images for occlude placement procedure. *Computers in Biology and Medicine*, Vol. 104, pp. 163-174
- [4] M. Habijan, H. Leventić, I. Galić, D. Babin. (2019). Estimation of the Left Ventricle Volume Using Semantic Segmentation, *Proceedings of the 61 st International Symposium ELMAR, Zadar, Croatia*, 23-25 September 2019, pp. 39-44.
- [5] Wang, H., Amini, A. A. (2012), Cardiac Motion and Deformation Recovery From MRI: A Review, *IEEE Transactions on Medical Imaging*, vol. 31, no. 2, pp. 487-503, doi: 10.1109/TMI.2011.2171706.
- [6] <https://www.nibib.nih.gov/science-education/science-topics/magnetic-resonance-imaging-mri> (5. travanj 2023)
- [7] “DeepMedic.”<https://deepmedic.org/#about> (18. ožujak 2023)
- [8] <https://towardsdatascience.com/the-evolution-of-deeplab-for-semantic-segmentation-95082b025571> (5. travanj 2023)
- [9] [https://en.wikipedia.org/wiki/Magnetic\\_resonance\\_imaging](https://en.wikipedia.org/wiki/Magnetic_resonance_imaging) (17. travanj 2023)
- [10] <https://www.healthline.com/health/body-planes#coronal-plane> (17. travanj 2023)
- [11] Malešić, I. Izrada anatomskih 3D modela pomoću računalne topografije, *Završni rad*, Karlovac University of Applied Sciences, <https://urn.nsk.hr/urn:nbn:hr:128:638492>
- [12] Carol Mitchell, Peter S. Rahko, Lori A. Blauwet, Barry Canaday, Joshua A. Finstuen, Michael C. Foster, Kenneth Horton, Kofo O. Ogunyankin, Richard A. Palma, Eric J. Velazquez. (2019), Guidelines for Performing a Comprehensive Transthoracic Echocardiographic Examination in Adults: Recommendations from the American Society of Echocardiography, *Journal of the American Society of Echocardiography*, Volume 32, Issue 1, pp. 1-64, doi: <https://doi.org/10.1016/j.echo.2018.06.004>.
- [13] <https://zmiclab.github.io/zxh/0/mmwhs/> (17. travanj 2023)
- [14] <https://brainerd.org/2012/09/23/the-nifti-file-format/> (17. travanj 2023)
- [15] <https://lmb.informatik.uni-freiburg.de/people/ronneber/u-net/> (17. travanj 2023)